

RAG - 1

RAG(Retrieval-Augmented Generation)란?

1. RAG의 의미

RAG는 **Retrieval-Augmented Generation**의 약자로, 우리말로로는 보통 **검색 증강 생성**이라고 부릅니다.

쉽게 말하면, **LLM이 스스로 알고 있는 내용만으로 답하는 것이 아니라, 외부 문서나 데이터에서 관련 정보를 먼저 찾아본 뒤 그 내용을 바탕으로 답변을 생성하는 방식**입니다.


일반적인 LLM은 학습된 지식에 의존해 답을 생성합니다.

하지만 최신 정보가 필요하거나, 회사 내부 문서·전문 자료·사용자 맞춤 데이터처럼 **모델이 원래 알지 못하는 정보**가 필요한 경우에는 한계가 있습니다.

이때 RAG를 사용하면 필요한 정보를 외부 지식원에서 검색하여, 더 정확하고 맥락에 맞는 답변을 만들 수 있습니다.

RAG란 무엇일까?

RAG는 AI가 답변하기 전에 관련 자료를 찾아보고, 그 내용을 바탕으로 답하게 하는 방식입니다.



쉽게 비유하면 | 시험 볼 때, 외워서만 답하는 것이 아니라 책에서 필요한 부분을 먼저 찾아보고 답하는 것과 비슷합니다.

왜 좋을까?			일반 AI와의 차이
더 정확한 답변	최신 정보 활용	회사/학교 문서 기반 답변 가능	일반 AI: 기억에 의존해 답변
			RAG 기반 AI: 자료를 찾아보고 답변

★ 즉, RAG는 ‘찾고(Retrieval) + 답하는(Generation)’ AI 방식입니다. 🚀

2. 왜 RAG가 필요한가?

대규모 언어모델은 매우 강력하지만 다음과 같은 한계가 있습니다.

- 학습 이후의 최신 정보를 모를 수 있음
- 특정 조직의 내부 문서나 개인 자료를 기본적으로 알 수 없음
- 사실과 다른 내용을 그럴듯하게 만들어내는 **환각(Hallucination)** 문제가 발생할 수 있음

RAG는 이러한 문제를 줄이기 위해 등장했습니다.

즉, 필요한 정보를 먼저 검색(Retrieval)하고, 그 검색 결과를 바탕으로 생성(Generation)하는 구조라고 이해하면 됩니다.

3. RAG의 작동 방식

RAG의 기본 흐름은 다음과 같습니다.



(1) 사용자가 질문을 입력한다

사용자가 시스템에 질문을 입력합니다.

예시:

“RAG는 왜 필요한가요?”

(2) 관련 문서를 검색한다

시스템은 질문과 관련된 문서 조각(chunk), 데이터, 지식베이스 내용을 검색합니다.

이 과정은 보통 벡터 검색(Vector Search), 키워드 검색, 또는 두 방식을 함께 사용하여 이루어집니다.

예시:

- RAG 개념 설명 문서
- LLM의 한계 정리 문서
- 환각 문제 사례 문서

(3) 검색된 정보를 질문과 함께 프롬프트로 구성한다

찾아온 자료를 그대로 보여주는 것이 아니라,

질문 + 검색된 문서 내용을 하나의 프롬프트로 구성하여 LLM에 전달합니다.

즉, 모델은 단순히 질문만 받는 것이 아니라

“이 질문에 답할 때 참고해야 할 자료”도 함께 받게 됩니다.

(4) LLM이 최종 답변을 생성한다

LLM은 검색된 정보를 참고하여 답변을 생성합니다.

따라서 일반적인 생성형 답변보다 더 근거가 있고, 더 정확하며, 더 맥락에 맞는 응답을 만들 수 있습니다.

4. 한눈에 보는 RAG 구조

질문 입력 → 관련 정보 검색 → 검색 결과를 포함한 프롬프트 구성 → LLM이 답변 생성

이 과정을 통해 LLM은 단순한 “기억 기반 응답기”가 아니라,

필요한 자료를 찾아보고 답하는 지능형 시스템처럼 동작하게 됩니다.

5. RAG의 핵심 구성 요소

1) Query

사용자가 입력하는 질문입니다.

RAG의 시작점이며, 어떤 정보를 찾아야 하는지를 결정합니다.

2) Retriever

질문과 관련된 문서를 찾는 역할을 합니다.

보통 문서를 작은 단위로 나누고, 이를 벡터로 변환한 뒤 유사한 내용을 검색합니다.

3) Knowledge Base

검색 대상이 되는 지식 저장소입니다.

PDF, 매뉴얼, 보고서, 사내 문서, 위키, 데이터베이스 등 다양한 자료가 포함될 수 있습니다.

4) Prompt Augmentation

검색된 내용을 질문과 결합하여 LLM이 이해할 수 있는 입력 형태로 만드는 과정입니다.

5) Generator

최종적으로 답변을 생성하는 LLM입니다.

검색된 자료를 참고해 자연어 응답을 생성합니다.

6. RAG의 장점

정확도 향상

외부 자료를 참고하기 때문에 사실에 더 가까운 답변을 생성할 수 있습니다.

최신 정보 반영 가능

모델을 다시 학습시키지 않아도, 최신 문서를 지식베이스에 추가하면 새로운 정보를 반영할 수 있습니다.

도메인 특화 응답 가능

의료, 법률, 교육, 게임 설정집, 기업 내부 문서처럼 특정 분야 자료를 연결하면 전문적인 답변이 가능합니다.

환각 감소

모델이 근거 없이 만들어내는 답변을 줄이는 데 도움을 줍니다.

7. RAG의 한계

검색 품질에 따라 성능이 달라진다

관련 없는 문서를 가져오면 답변 품질도 떨어집니다.

즉, RAG의 성능은 검색기의 품질에 크게 영향을 받습니다.

문서 분할(Chunking)이 중요하다

문서를 너무 크게 자르면 불필요한 정보가 많아지고, 너무 작게 자르면 맥락이 끊길 수 있습니다.

검색 결과가 항상 정답은 아니다

검색된 문서 자체가 부정확하거나 오래된 자료일 수 있습니다.

따라서 지식베이스 품질 관리도 매우 중요합니다.

시스템 구조가 단순 LLM보다 복잡하다

임베딩, 벡터DB, 검색기, 프롬프트 설계 등 추가 구성이 필요합니다.

8. 일반 LLM과 RAG의 차이

구분	일반 LLM	RAG
정보 출처	모델이 학습한 내부 지식	외부 문서 + 모델 지식
최신 정보 반영	어려움	상대적으로 쉬움
내부 문서 활용	어려움	가능
환각 감소	제한적	비교적 유리
시스템 복잡도	단순	더 복잡

9. RAG 활용 사례

사내 문서 기반 챗봇

회사 규정, 업무 매뉴얼, 회의록 등을 검색하여 직원 질문에 답변하는 시스템

교육용 질의응답 시스템

교재, 강의자료, 논문 요약 자료를 기반으로 학생 질문에 답변하는 시스템

의료/법률 보조 시스템

전문 문서와 가이드라인을 검색해 근거 중심 응답을 제공하는 시스템

게임 NPC 대화 시스템

NPC의 성격, 배경 설정, 세계관 문서를 검색하여

일관성 있는 대화와 몰입감 있는 상호작용을 생성하는 시스템

10. 예시로 이해하는 RAG

질문

“RAG는 왜 일반 챗봇보다 더 신뢰할 수 있나요?”

일반 LLM 방식

모델이 학습한 기억을 바탕으로 답변함

→ 때로는 최신 정보 부족, 근거 부족, 환각 가능성 존재

RAG 방식

관련 문서 검색

→ 검색된 자료를 질문과 함께 LLM에 전달

→ 근거를 참고해 답변 생성

결과

RAG는 단순 추측보다 **문서 기반의 답변**을 만들 가능성이 높아집니다.