

RAG - 2

1. RAG 시스템 구축이란?

RAG 시스템 구축이란, 대규모 언어모델(LLM)이 외부 문서를 참고하여 더 정확한 답변을 생성할 수 있도록 문서를 준비하고, 검색 가능한 형태로 저장하고, 질문이 들어오면 관련 정보를 찾아 답변에 반영하는 전체 구조를 만드는 과정입니다.

즉, RAG는 단순히 "검색해서 붙이는 기술"이 아니라,

다음 두 가지 흐름으로 이루어진 시스템입니다.

- **사전 구축 단계(Indexing 단계):** 문서를 불러오고, 잘게 나누고, 임베딩하고, 저장하는 단계
- **질의응답 단계(Retrieval + Generation 단계):** 사용자의 질문과 관련된 문서를 찾아 LLM이 답변을 생성하는 단계

2. RAG 시스템 구축 순서



RAG 시스템 구축의 기본 순서

- Load
- Split
- Embed
- Store

이 네 단계는 RAG를 구축할 때 가장 기본이 되는 흐름입니다.

3. 1단계: Load

의미

Load는 **문서를 불러오는 단계**입니다.

RAG 시스템이 참고할 자료를 먼저 준비해야 하므로, PDF, TXT, Word, HTML, 웹페이지, 데이터베이스 문서 등을 읽어옵니다.

왜 필요한가?

LLM은 기본적으로 외부 문서를 자동으로 아는 것이 아니기 때문에, 우리가 참고시키고 싶은 자료를 먼저 시스템 안으로 가져와야 합니다.

예시

- 회사 매뉴얼 PDF 불러오기
- 수업 교안 텍스트 불러오기
- 게임 NPC 설정 문서 불러오기
- 웹사이트 FAQ 데이터 불러오기

쉬운 비유

Load는 **도서관에 책을 들여오는 작업**과 같습니다.

아무리 좋은 검색 시스템이 있어도 책이 없으면 찾을 수 없습니다.

4. 2단계: Split

의미

Split은 불러온 문서를 **작은 단위로 나누는 단계**입니다.

RAG에서는 보통 긴 문서를 그대로 저장하지 않고, 문단이나 일정 길이 기준으로 나누어 저장합니다. 이 작은 조각을 흔히 **Chunk**라고 부릅니다.

왜 필요한가?

문서 전체를 한 번에 검색하면 너무 크고 비효율적입니다.

또한 질문과 직접 관련된 부분만 찾아야 하므로, 문서를 잘게 나누어야 검색 정확도가 높아 집니다.

예시

하나의 20페이지 PDF를 그대로 저장하는 대신,

- 1페이지 단위
- 문단 단위
- 500자~1000자 단위
- 일정 토큰 수 단위

로 나누어 저장할 수 있습니다.

중요한 점

너무 크게 나누면 관련 없는 내용이 많이 섞이고,

너무 작게 나누면 문맥이 끊겨 의미가 약해질 수 있습니다.

즉, Split은 단순 분할이 아니라

검색 성능과 문맥 유지 사이의 균형을 잡는 작업입니다.

쉬운 비유

Split은 책 전체를 보관하는 대신, 주제별 카드로 나누어 정리하는 것과 비슷합니다.

5. 3단계: Embed

의미

Embed는 각 문서 조각(Chunk)을 **숫자 벡터 형태로 변환하는 단계**입니다.

이 과정을 통해 컴퓨터는 문장의 의미적 유사성을 비교할 수 있게 됩니다.

왜 필요한가?

사용자의 질문과 문서 조각이 의미상 얼마나 비슷한지를 계산하려면,

텍스트를 수치화해야 합니다.

이때 사용하는 것이 **임베딩(Embedding)**입니다.

예시

질문:

“RAG의 장점은 무엇인가요?”

문서 A:

“RAG는 외부 지식을 검색하여 환각을 줄이는 데 도움을 준다.”

문서 B:

“오늘 날씨는 맑고 기온이 높다.”

이 경우 문서 A가 질문과 의미적으로 더 가깝기 때문에, 임베딩 공간에서 더 가까운 위치에 놓이게 됩니다.

쉬운 비유

Embed는 문장을 **의미 좌표**로 바꾸는 작업입니다.

비슷한 뜻을 가진 문장끼리는 좌표상 가까운 위치에 모이게 됩니다.

6. 4단계: Store

의미

Store는 임베딩된 문서 조각들을 **벡터 데이터베이스(Vector DB)** 또는 검색 가능한 저장소에 저장하는 단계입니다.

왜 필요한가?

질문이 들어왔을 때 관련 문서를 빠르게 찾으려면,
미리 임베딩된 벡터들을 정리해서 저장해두어야 합니다.

저장 대상

보통 다음 정보가 함께 저장됩니다.

- 문서 조각 텍스트
- 임베딩 벡터
- 문서 출처 정보
- 메타데이터(파일명, 페이지 번호, 카테고리 등)

대표적인 저장소 예시

- FAISS
- Chroma
- Pinecone
- Weaviate
- Milvus

쉬운 비유

Store는 잘 정리된 카드 서랍에 자료를 꽂아두는 작업입니다.

나중에 질문이 들어오면 거기서 가장 관련 있는 카드를 빠르게 꺼낼 수 있습니다.

7. 질문이 들어온 뒤의 동작 과정

RAG 시스템은 문서를 저장해두는 것만으로 끝나지 않습니다.

실제 사용 시에는 다음과 같은 단계로 답변이 생성됩니다.

(1) 사용자 질문 입력

사용자가 질문을 입력합니다.

예시:

“RAG에서 Split 단계가 중요한 이유는 무엇인가요?”

(2) 질문 임베딩

질문도 문서와 동일한 방식으로 임베딩 벡터로 변환합니다.

(3) 유사한 문서 검색

질문 벡터와 가까운 문서 조각들을 벡터DB에서 검색합니다.


(4) 프롬프트 구성

질문 + 검색된 문서들을 함께 묶어 하나의 프롬프트를 만듭니다.

(5) LLM이 최종 답변 생성

LLM은 검색된 자료를 참고하여 답변을 생성합니다.

8. 전체 흐름 정리



사전 구축 단계

Load → Split → Embed → Store

실행 단계

Question → Retrieve → Prompt Augmentation → LLM → Answer

즉, 앞의 네 단계는 지식베이스를 만드는 과정이고,

뒤의 단계는 그 지식베이스를 활용해 답변하는 과정입니다.